Maestría en Inteligencia Artificial Aplicada

TC5035.10 — Proyecto Integrador (Grupo 10) · Trimestre septiembre – diciembre 2026

AVANCE 5 · MODELO FINAL

Planograma: IA para detección de productos y ubicación

Ensambles homogéneos y heterogéneos para identificar el SKU de cada producto contra una galería de referencia, y elección del modelo final

Equipo 48

Jesús Soto Medrano	A01794746
Germán Eduardo Rodríguez Vázquez	A01796325
Oscar Alberto Ramírez Anaya	A01795438

Profesora: Dra. Grettel Barceló Alonso

Asesor: Dr. Raúl Valente Ramírez

Sponsor: Dr. Juan Arturo Nolazco Flores, Director del Hub de Ciencia de Datos, Tecnológico de Monterrey

Organización: empresa sponsor

1 de noviembre de 2026

Índice

1. Introducción 4

1.1 Propósito 4

1.2 Recomendaciones de la sesión con la empresa sponsor 4

1.3 Datos usados en esta ejecución 4

2. Modelos individuales 5

2.1 Aprendizaje de métrica 5

2.2 Resultados individuales 6

3. Modelos de ensamble 6

3.1 Fuga en la validación cruzada dentro de entrenamiento 7

3.2 Resultados de la optimización 7

4. Tabla comparativa y elección del modelo final 8

5. Análisis del modelo final 9

5.1 SKU nuevos 9

5.2 Matriz de confusión 10

5.3 Curvas ROC y precisión-recall: productos desconocidos 11

5.4 Puntajes y umbral de decisión 11

5.5 Importancia de los modelos base 12

5.6 Desempeño por SKU 12

6. Ejecución del 2 de noviembre con los datos de la empresa sponsor 13

7. Conclusiones 13

Anexo A. Declaración de uso de IA y contribución del equipo 13

Bibliografía 14

Índice de tablas

Tabla 1. Conjunto de datos de esta ejecución 4

Tabla 2. Modelos individuales en prueba 6

Tabla 3. Ensambles construidos 6

Tabla 4. Top-1 de cada modelo base según dónde se mide 7

Tabla 5. Comparación en prueba, ordenada por F1 macro 8

Tabla 6. Top-1 y top-5 en SKU vistos y nuevos (prueba) 9

Tabla 7. Uso de herramientas de IA 13

Tabla 8. Contribución individual 13

Índice de figuras

Figura 1. Top-1 en validación y pérdida de entrenamiento por época para las tres pérdidas de métrica 6

Figura 2. F1 macro en prueba por modelo y relación entre calidad y latencia; el número de cada punto es la posición en la Tabla 5 9
Figura 3. Matriz de confusión normalizada por fila de los 15 SKU que participan en más errores 10
Figura 4. Curvas ROC y precisión-recall para detectar un SKU que no está en la galería 11
Figura 5. Distribución del puntaje del candidato elegido en aciertos y errores, y exactitud de lo decidido automáticamente al subir el umbral 11
Figura 6. Coeficientes del meta-modelo del stacking y caída del F1 macro al retirar cada modelo base 12
Figura 7. F1 por SKU con el modelo final, por grupo de producto; el asterisco señala los SKU nuevos 12

1. Introducción

1.1 Propósito

Este documento reporta el cierre de la fase de **Ingeniería del modelo** del proyecto, conforme a CRISP-ML(Q) (Visengeriyeva et al., 2023). Los mejores modelos individuales del Avance 4 se combinan en **modelos de ensamble** para identificar el SKU de cada producto, se comparan contra los individuales y se elige el modelo final con criterios de negocio. Se cubren los objetivos 3.5 (mejorar el rendimiento combinando las fortalezas de distintos modelos) y 3.6 (evaluar la calidad de las predicciones en datos no vistos).

La libreta ejecutada que respalda cada cifra, `Avance5.48.ipynb`, está en el repositorio `https://github.com/oscar-ramirez-anaya/Avance5_Equipo48`.

1.2 Recomendaciones de la sesión con la empresa sponsor

En la revisión del Avance 4 con la empresa sponsor, el 28 de octubre de 2026, se acordó cómo cerrar el pipeline del planograma: foto del anaquel, detector de una sola clase, recortes, embedding, comparación contra una galería de SKU y planograma. Las recomendaciones que guían este avance son:

1. **Galería de SKU por carpeta.** El nombre de cada carpeta es el SKU y sus fotos son las referencias. Un recorte se identifica por similitud coseno contra la galería, con un umbral para declarar «desconocido». Un SKU nuevo se da de alta agregando su carpeta, sin reentrenar.
2. **Aprendizaje de métrica** en lugar del entrenamiento auto-supervisado del Avance 4: ancla y positivo del mismo SKU, negativo de otro SKU, procesados por el mismo modelo.
3. **DINOv2 ViT-S/14** como modelo base, con lotes de 2 a 4 fotos por SKU, distancia coseno y destilación hacia el modelo original.
4. **Comparar tres pérdidas**: triplet con minado semi-difícil, multi-similitud y SupCon.
5. **Fusión con color**: combinar DINOv2 con el histograma HSV, ganador del Avance 4.
6. **Dejar SKU fuera del entrenamiento** para medir el reconocimiento de productos nuevos.
7. **Pendientes:** reentrenar el detector con refrigeradores, correr el pipeline completo en uno o dos refrigeradores y solicitar a la empresa sponsor el planograma esperado.

1.3 Datos usados en esta ejecución

Esta entrega se ejecutó con datos dummy. Durante la ventana de entrega no hubo acceso a la infraestructura de la empresa sponsor, y por el acuerdo de confidencialidad sus datos no pueden salir de ella. Como datos dummy se usó un conjunto público con la misma estructura que la galería de SKU: el *Grocery Store Dataset* (Klasson et al., 2019), con licencia MIT. Contiene fotos tomadas con un teléfono en supermercados, organizadas en una carpeta por producto, y una imagen icónica de catálogo por producto (Tabla 1).

Tabla 1. Conjunto de datos de esta ejecución

Grupo	Productos	Entrenamiento (galería)	Validación	Prueba
Empaque (leche, jugo, yogur, soya, avena)	31	864	100	781

Grupo	Productos	Entrenamiento (galería)	Validación	Prueba
Fruta	28	1 142	111	1 117
Verdura	22	634	85	587
Total	**81**	**2 640**	**296**	**2 485**

> **DATOS DUMMY Y EJECUCIÓN CON LOS DATOS DE LA EMPRESA SPONSOR**
>
> Las cifras de este reporte **no** son resultados sobre datos de la empresa sponsor; son evidencia del método. **El lunes 2 de noviembre de 2026 la misma libreta se ejecutará con los datos de la empresa sponsor, dentro de su infraestructura**, cambiando solo la ruta de los datos. En esa ejecución se harán también los ensambles del detector (fusión de cajas de FCOS y Faster R-CNN). El repositorio se actualizará solo con métricas y gráficas agregadas, sin imágenes ni información confidencial.

Protocolo. Se usa la partición oficial del conjunto, que es por foto. Las fotos de entrenamiento forman la galería, y un recorte se identifica con el SKU cuya carpeta contiene la foto más parecida. Diez productos se dejan fuera del entrenamiento del embedding, pero sí están en la galería: así se mide qué tan bien se reconoce un SKU dado de alta sin reentrenar. La **métrica principal es el F1 macro**, como en el Avance 3, porque cada SKU pesa igual en el anaquel. Como métricas de apoyo se usan top-1, top-5 (útil para revisión asistida) y el rango recíproco medio (MRR).

2. Modelos individuales

Se usan como base los modelos individuales de la fase previa y el embedding recomendado en la sesión (Tabla 2). Los modelos de galería clasifican con kNN coseno: el puntaje de cada SKU es la similitud máxima contra las fotos de su carpeta.

2.1 Aprendizaje de métrica

Se ajustan los 4 últimos bloques de DINOv2 ViT-S/14 con AdamW (tasa de 1e-5) durante 8 épocas. Cada lote tiene 64 fotos, 4 por SKU. A la pérdida de métrica se suma una destilación hacia el DINOv2 original ($\lambda = 1$). Las tres pérdidas mejoran mucho el top-1 en validación (Figura 1):

- SupCon: de 0.676 a 0.902, en la época 6;
- triplet semi-difícil: 0.899, en la época 8;
- multi-similitud: 0.885, en la época 7.

SupCon y triplet empatan en la práctica: la diferencia es menos de una foto de validación. Se elige SupCon porque converge más rápido. Cada entrenamiento tardó unos 280 segundos en la GPU de una Mac M4 Pro.

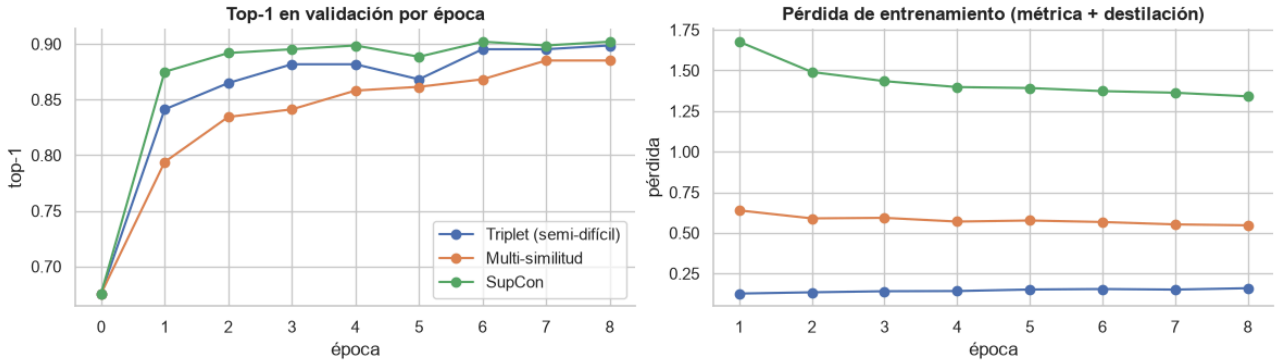


Figura 1. Top-1 en validación y pérdida de entrenamiento por época para las tres pérdidas de métrica. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

2.2 Resultados individuales

Tabla 2. Modelos individuales en prueba

Modelo	Origen	F1 macro	Top-1	Top-5	MRR
Histograma HSV + kNN	Final del Avance 4	0.387	0.418	0.804	0.585
DINOv2 ViT-S/14 + kNN	Finalista del Avance 4	0.668	0.701	0.948	0.809
DINOv2 + métrica (SupCon) + kNN	Recomendación de la sesión	0.940	0.934	0.998	0.965
DINOv2 + métrica, solo imagen icónica	Galería de una foto por SKU	0.748	0.751	0.974	0.851
Regresión logística sobre DINOv2 + métrica	Algoritmo del Avance 3	0.954	0.953	0.999	0.973

El aprendizaje de métrica es el cambio de mayor impacto: sube el F1 macro de DINOv2 de 0.668 a 0.940. El histograma HSV cae a 0.387, porque aquí hay frutas y verduras de colores parecidos y fotos con iluminación muy variable. Con los recortes de la empresa sponsor, de la misma cámara y el mismo anaquel, el color separaba mejor, así que su papel debe volver a medirse con la galería real.

3. Modelos de ensamble

Tabla 3. Ensambles construidos

#	Ensamble	Estrategia	Modelos base	Optimización
E1	Bosque aleatorio (bagging)	Homogénea	Árboles sobre [HSV, DINOv2 + métrica]	Optuna, 15 pruebas
E2	Gradient boosting	Homogénea	Árboles secuenciales sobre PCA de [HSV, DINOv2 + métrica]	Optuna, 6 pruebas

#	Ensamble	Estrategia	Modelos base	Optimización
E3	Votación ponderada	Heterogénea	HSV, DINOv2, DINOv2 + métrica, icónica	Optuna sobre los pesos, 80 pruebas
E4	Stacking	Heterogénea	Los mismos cuatro, con un meta-modelo de regresión logística	Rejilla sobre C con validación cruzada agrupada
E5	Blending	Heterogénea	Top-5 de DINOv2 + métrica re-ordenado con HSV	Peso α en validación

Los ensambles heterogéneos usan los mejores modelos individuales: HSV y DINOv2 del Avance 4, y DINOv2 con métrica de la sección 2. El meta-modelo del stacking no aprende un peso por SKU. Recibe, para cada par (recorte, SKU candidato), los puntajes estandarizados de las cuatro bases y su distancia al mejor candidato, y estima la probabilidad de que ese candidato sea el correcto. Así, **un SKU nuevo se agrega a la galería sin reentrenar**.

3.1 Fuga en la validación cruzada dentro de entrenamiento

La primera opción fue ajustar los ensambles con puntajes fuera de partición dentro de entrenamiento. La Tabla 4 muestra que esa estimación tiene fuga. Las fotos de cada producto se tomaron en ráfagas, así que en entrenamiento cada foto tiene gemelas casi idénticas en las otras particiones.

Tabla 4. Top-1 de cada modelo base según dónde se mide

Modelo base	Fuera de partición (entrenamiento)	Validación	Prueba
HSV	0.949	0.358	0.418
DINOv2	0.951	0.676	0.701
DINOv2 + métrica	0.996	0.902	0.934
Imagen icónica	0.795	0.784	0.751

Por eso **todos los hiperparámetros, pesos y meta-modelos se ajustaron con el conjunto de validación**, que es de otra sesión de fotos, y la prueba se usó una sola vez. Lo mismo aplica a las carpetas de la empresa sponsor, donde las capturas de un SKU son de una misma sesión (Avance 3).

3.2 Resultados de la optimización

- **E1:** 600 árboles, `max_features = log2`, hoja mínima de 2 y clases balanceadas; F1 en validación de 0.913.
- **E2:** tasa de 0.084, 25 hojas y 200 iteraciones; F1 en validación de 0.688.
- **E3:** pesos de 0.94 para DINOv2 + métrica, 0.43 para DINOv2, 0.12 para icónica y 0.06 para HSV.
- **E4:** C = 10 (F1 de 0.881 en la validación cruzada agrupada).
- **E5:** α = 0.95; HSV casi no cambia el orden del top-5.

4. Tabla comparativa y elección del modelo final

Tabla 5. Comparación en prueba, ordenada por F1 macro

#	Modelo	Tipo	F1 macro	Top-1	Top-5	MRR	Entrenamiento (s)	Inferencia (ms/img)	Alta de SKU
1	Regresión logística (DINOv2 + métrica)	Individual	0.954	0.953	0.999	0.973	0.1	3.8	Reentrenar
2	E1 Bosque aleatorio	Homogéneo	0.947	0.945	0.999	0.970	47.2	3.9	Reentrenar
3	**E4 Stacking**	**Heterogéneo**	**0.940**	**0.937**	**1.000**	**0.966**	**0.1**	**7.6**	**Sin reentrenar**
4	DINOv2 + métrica + kNN	Individual	0.940	0.934	0.998	0.965	283.9	3.8	Sin reentrenar
5	E5 Blending	Heterogéneo	0.935	0.931	0.998	0.963	0.0	3.9	Sin reentrenar
6	E3 Votación ponderada	Heterogéneo	0.930	0.928	0.999	0.961	0.1	7.6	Sin reentrenar
7	E2 Gradient boosting	Homogéneo	0.753	0.771	0.942	0.848	157.5	4.2	Reentrenar
8	DINOv2 + métrica, imagen icónica	Individual	0.748	0.751	0.974	0.851	283.9	3.8	Sin reentrenar
9	DINOv2 + kNN	Individual	0.668	0.701	0.948	0.809	9.9	3.8	Sin reentrenar
10	HSV + kNN	Individual	0.387	0.418	0.804	0.585	0.3	0.1	Sin reentrenar

El tiempo de entrenamiento incluye la optimización de hiperparámetros de cada modelo, sin sumar el de sus bases. El embedding con métrica, del que dependen casi todos, tardó 284 s. La latencia se midió en la GPU de una Mac (MPS) y se medirá en el Jetson con FP16.

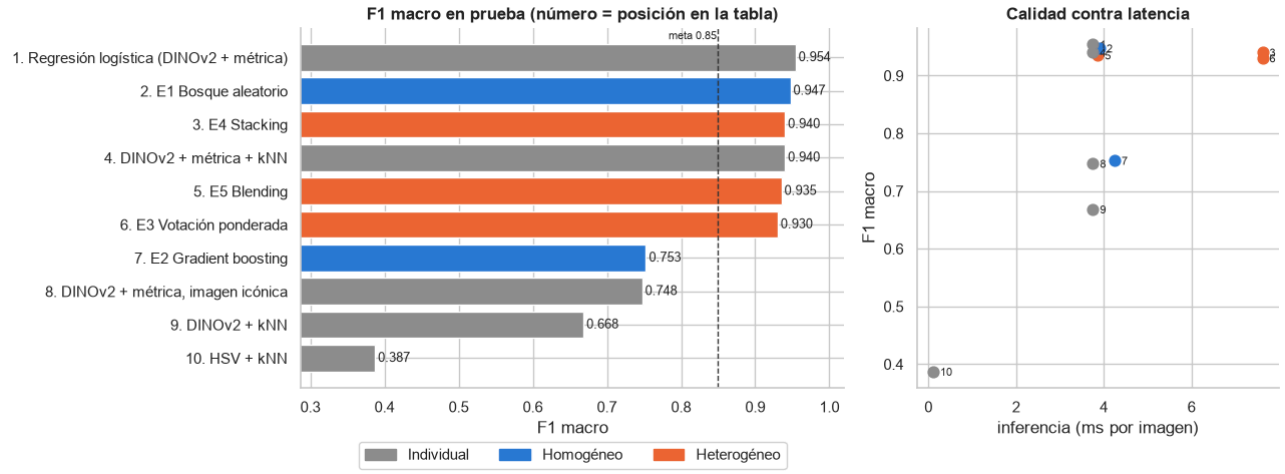


Figura 2. F1 macro en prueba por modelo y relación entre calidad y latencia; el número de cada punto es la posición en la Tabla 5. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

Modelo final: E4 Stacking. Todos los modelos, salvo E2 y los individuales sin entrenar, superan la meta de negocio de 0.85. La regla de elección se definió en el Avance 4: dar de alta un SKU nuevo agregando su carpeta, sin reentrenar, porque el surtido de los anaqueles cambia con frecuencia.

Entre los modelos que lo permiten, el stacking tiene el mayor F1 macro (0.940) y el mejor top-1 (0.937). Con top-5 de 1.000, en revisión asistida el SKU correcto siempre está entre los cinco primeros. Además es el más robusto con SKU nuevos (Tabla 6).

La regresión logística (+0.014) y el bosque aleatorio (+0.007) son algo más precisos, pero obligan a reentrenar y volver a validar con cada cambio de catálogo. Una diferencia de una a dos fotos por cada cien no compensa ese costo de operación.

Costos del stacking: su ganancia sobre DINOv2 con métrica sola es pequeña en SKU vistos (+0.003 de top-1), y necesita dos pasadas de DINOv2 (7.6 ms por imagen). Esa latencia es baja frente a los cerca de 100 ms por foto del detector en el Jetson. El gradient boosting fue el ensamble más débil: con 81 clases y unas 30 fotos por clase, los árboles sobre componentes principales pierden la geometría del embedding.

5. Análisis del modelo final

5.1 SKU nuevos

Tabla 6. Top-1 y top-5 en SKU vistos y nuevos (prueba)

Modelo	Top-1 vistos	Top-1 nuevos	Top-5 vistos	Top-5 nuevos
DINOv2 + kNN	0.708	0.645	0.955	0.900
DINOv2 + métrica + kNN	0.935	0.928	0.998	1.000
E4 Stacking	**0.937**	**0.941**	**1.000**	**1.000**

El aprendizaje de métrica generaliza a productos que no vio al entrenar: 0.928 de top-1 en SKU nuevos contra 0.935 en vistos. El stacking llega a 0.941 en los SKU nuevos, porque la imagen icónica y el DINOv2 original aportan señal que no depende del entrenamiento. Esto respalda el flujo de alta sin reentrenar. Solo se probaron 10 productos, así que debe repetirse con la galería de la empresa sponsor.

5.2 Matriz de confusión

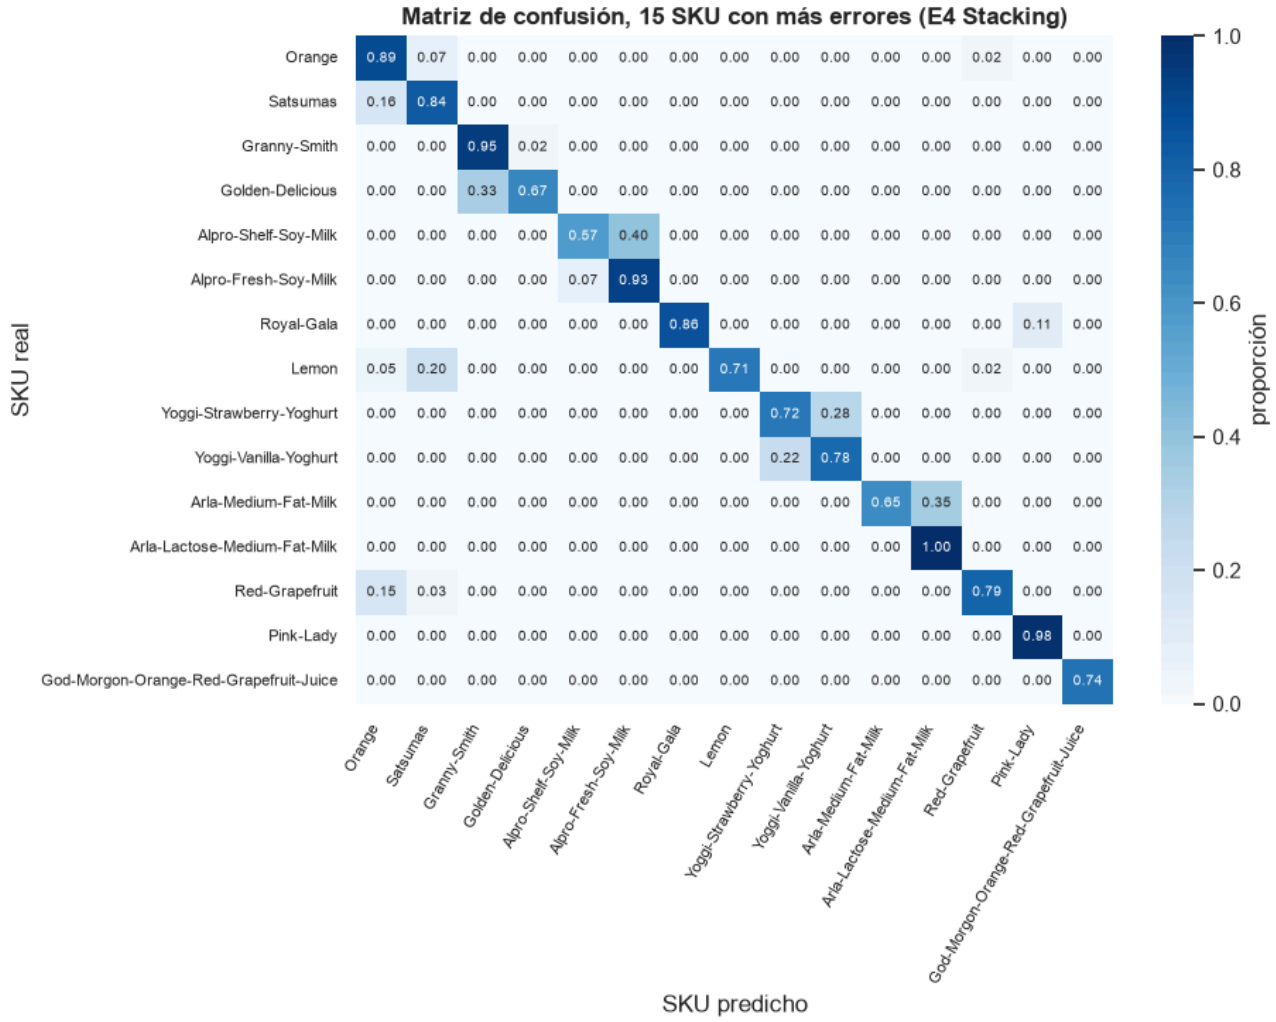


Figura 3. Matriz de confusión normalizada por fila de los 15 SKU que participan en más errores. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

Los errores se concentran en **variantes de la misma marca o familia**:

- Golden Delicious con Granny Smith (15 errores);
- leche Arla semidescremada con su versión deslactosada (12);
- leche de soya Alpro de anaquel con la refrigerada (12);
- satsumas con naranja (11);
- yogur Yoggi de fresa con el de vainilla (9).

En los productos en empaque cambia solo un texto o un color pequeño del envase, el mismo riesgo identificado para los refrigeradores de la empresa sponsor. Esto orienta dos acciones: usar esas variantes como negativos difíciles en el entrenamiento con métrica, y probar CLIP o SigLIP, que leen texto y logotipos.

5.3 Curvas ROC y precisión-recall: productos desconocidos

Para medir si el modelo distingue un producto que no está en la galería, se retiraron de ella los 10 SKU nuevos y sus fotos de prueba se trataron como desconocidas (clase positiva).

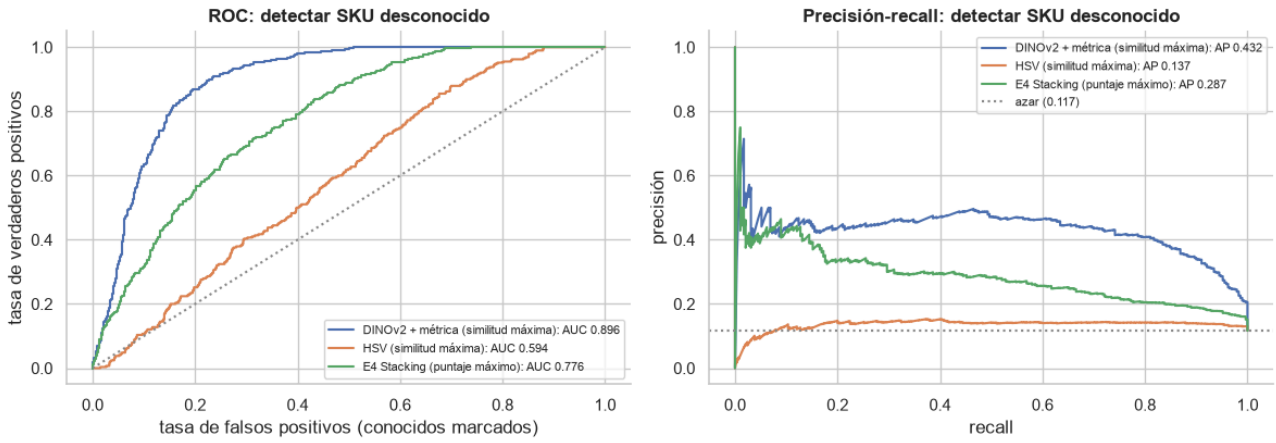


Figura 4. Curvas ROC y precisión-recall para detectar un SKU que no está en la galería. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

Esta es la limitación principal del modelo elegido. La similitud máxima de DINOv2 con métrica separa mejor los desconocidos: AUC de 0.896 y precisión promedio de 0.432, frente a un azar de 0.117. El stacking queda en 0.776 y 0.287, porque su puntaje está construido para elegir entre candidatos y no para medir qué tan familiar es el producto. HSV casi no separa (AUC de 0.594).

Se recomienda un pipeline en dos pasos: primero, un filtro de «desconocido» con umbral sobre la similitud de DINOv2 con métrica; después, la identificación con el stacking. Con una precisión promedio de 0.43, los casos marcados como desconocidos deben ir a revisión humana.

5.4 Puntajes y umbral de decisión

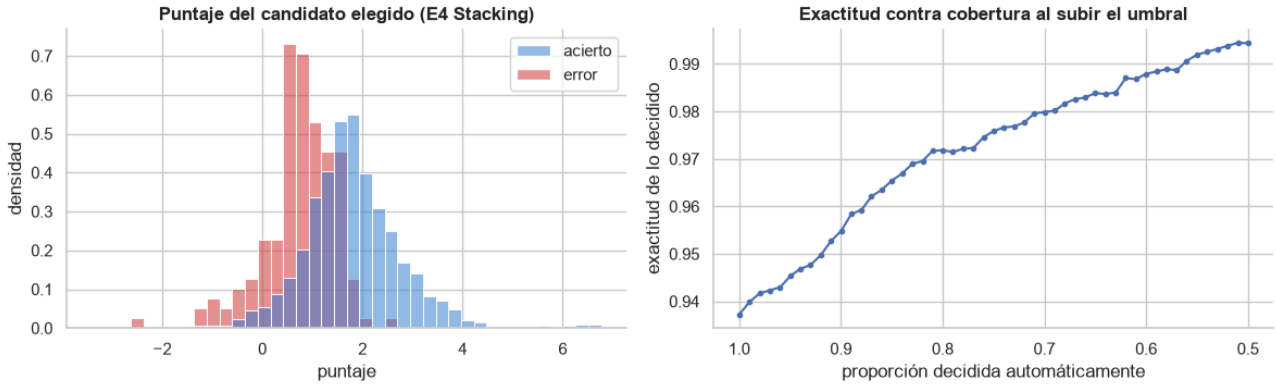


Figura 5. Distribución del puntaje del candidato elegido en aciertos y errores, y exactitud de lo decidido automáticamente al subir el umbral. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

Los aciertos tienen puntajes de 1.5 a 4 y los errores de 0 a 1.5, con una zona de traslape. Al subir el umbral, la exactitud de lo que se decide automáticamente sube de 0.937 (todo) a 0.955 (90 %), 0.972 (80 %) y 0.980 (70 %).

Una política razonable es decidir automáticamente alrededor del 80 % de los productos y mandar el resto a revisión con sus cinco candidatos. El umbral final se fijará con la empresa sponsor según el costo de una alerta falsa frente al de una revisión manual.

5.5 Importancia de los modelos base

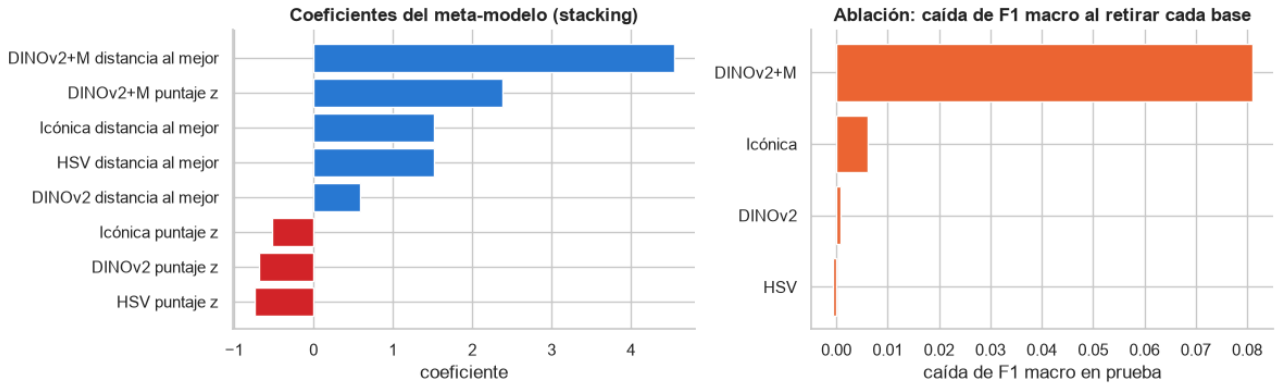


Figura 6. Coeficientes del meta-modelo del stacking y caída del F1 macro al retirar cada modelo base. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

El stacking depende sobre todo de DINOv2 con métrica. Retirarlo baja el F1 macro en 0.081; retirar la imagen icónica, en 0.006. El DINOv2 original y el HSV casi no cambian el resultado.

Los coeficientes más altos son la distancia al mejor candidato de DINOv2 con métrica (4.5) y su puntaje estandarizado (2.4). Los coeficientes negativos de los puntajes estandarizados deben leerse junto con las distancias al mejor, con las que están correlacionados. El color no aporta en este conjunto, a diferencia del Avance 4 con datos de la empresa sponsor; su peso debe volver a estimarse con la galería real.

5.6 Desempeño por SKU

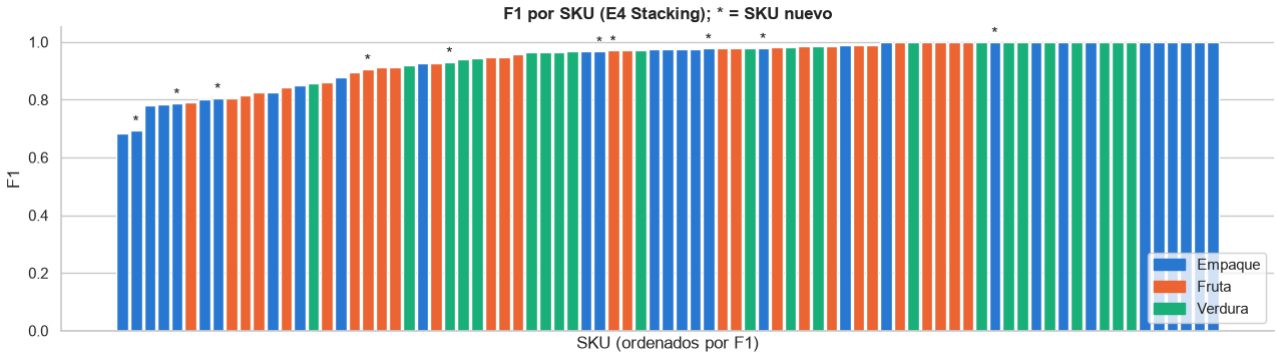


Figura 7. F1 por SKU con el modelo final, por grupo de producto; el asterisco señala los SKU nuevos. Elaboración propia con datos del Grocery Store Dataset (Klasson et al., 2019).

Las verduras son el grupo más fácil (F1 medio de 0.972) y las frutas siguen (0.935). Los productos en empaque son los más difíciles (0.923; mínimo de 0.683), justamente el grupo más parecido a los productos de refrigerador. Los SKU con menor F1 tienen todos una variante casi idéntica en la galería: yogur Yoggi de vainilla y de fresa, leches de soya Alpro y leche Arla semidescremada. Para la empresa sponsor, la prioridad de captura de fotos y de negativos difíciles deben ser las presentaciones de una misma marca.

6. Ejecución del 2 de noviembre con los datos de la empresa sponsor

1. Copiar al Jetson las carpetas de SKU y las escenas de refrigerador, sin que salgan de la infraestructura de la empresa sponsor, y ejecutar la libreta con la ruta de esos datos.
2. Ensambles del detector: fusión ponderada de cajas (WBF; Solovyev et al., 2021) de FCOS y Faster R-CNN v2, que es heterogénea, y FCOS con aumentos en prueba, que es homogénea. Se ajustarán en validación con el protocolo del Avance 4.
3. Correr el pipeline completo en uno o dos refrigeradores (detección, SKU, hilera y posición, huecos), reportando solo resultados agregados.
4. Solicitar a la empresa sponsor el planograma esperado y la correspondencia de las carpetas de agrupamiento con productos.

7. Conclusiones

1. **Ensambles.** Se construyeron cinco con optimización de hiperparámetros: dos homogéneos (bosque aleatorio y gradient boosting) y tres heterogéneos (votación, stacking y blending) sobre los mejores modelos individuales.
2. **Mayor mejora.** Viene del aprendizaje de métrica recomendado por la empresa sponsor: el F1 macro pasa de 0.668 a 0.940, y los SKU nuevos se reconocen casi igual que los vistos.
3. **Modelo final: stacking.** F1 macro de 0.940, top-1 de 0.937 y top-5 de 1.000. Es el mejor de los modelos que permiten dar de alta un SKU sin reentrenar.
4. **Hallazgo metodológico.** Ajustar ensambles con validación cruzada dentro de las fotos de entrenamiento tiene fuga, por las ráfagas de fotos. Hay que ajustar con fotos de otra sesión.
5. **Limitaciones.** Las cifras son de datos dummy y no de la empresa sponsor; el lunes 2 de noviembre se ejecuta con sus datos. Detectar productos desconocidos todavía no es confiable para automatizar. Los ensambles del detector están pendientes.

Anexo A. Declaración de uso de IA y contribución del equipo

Tabla 7. Uso de herramientas de IA

Herramienta utilizada	Propósito de uso	Responsabilidad: qué revisó o validó el equipo
Anthropic. (2026). Claude (Opus 5.5) [Modelo de lenguaje grande]. https://claude.ai/	Generar código de la libreta (carga de datos, aprendizaje de métrica, ensambles, optimización con Optuna y gráficas), búsqueda de un conjunto público como datos dummy, con la misma estructura que la galería de SKU, apoyo en la redacción de las interpretaciones y del reporte.	El equipo definió los modelos, las pérdidas y los ensambles a partir de la sesión con la empresa sponsor del 28 de octubre, revisó el código generado, ejecutó la libreta completa de principio a fin y validó cada cifra e interpretación contra las salidas.

Tabla 8. Contribución individual

Integrante	Contribución al avance
Oscar Alberto Ramírez Anaya	Incorporación de las recomendaciones de la sesión con la empresa sponsor, selección y preparación de los datos dummy, entrenamiento del embedding con aprendizaje de métrica, ensambles homogéneos (bosque aleatorio y gradient boosting), ejecución de la libreta, reporte y repositorio.
Jesús Soto Medrano	Propuesta de modelos y pérdidas de métrica en la sesión con la empresa sponsor (triplet, multi-similitud, SupCon y fusión con HSV), ensambles heterogéneos (votación, stacking y blending), tabla comparativa, elección del modelo final y análisis de las gráficas.

Bibliografía

Akiba, T., Sano, S., Yanase, T., Ohta, T., y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623–2631). ACM. https://doi.org/10.1145/3292500.3330701

Breiman, L. (1996). Bagging predictors. *Machine Learning, 24*(2), 123–140. https://doi.org/10.1007/BF00058655

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Khosla, P., Teterwak, P., Wang, C., Sarna, A., Tian, Y., Isola, P., Maschinot, A., Liu, C., y Krishnan, D. (2020). Supervised contrastive learning. En *Advances in Neural Information Processing Systems 33* (pp. 18661–18673).

Klasson, M., Zhang, C., y Kjellström, H. (2019). A hierarchical grocery store image dataset with visual and semantic labels. En *2019 IEEE Winter Conference on Applications of Computer Vision* (pp. 491–500). IEEE. https://doi.org/10.1109/WACV.2019.00058

Musgrave, K., Belongie, S., y Lim, S.-N. (2020). PyTorch metric learning. arXiv. https://doi.org/10.48550/arXiv.2008.09164

Oquab, M., Darcet, T., Moutakanni, T., et al. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Schroff, F., Kalenichenko, D., y Philbin, J. (2015). FaceNet: A unified embedding for face recognition and clustering. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (pp. 815–823). IEEE. https://doi.org/10.1109/CVPR.2015.7298682

Singh, A. (2023, 14 de julio). *Comprehensive guide to ensemble learning (with Python codes)*. Analytics Vidhya. https://www.analyticsvidhya.com/blog/2018/06/comprehensive-guide-for-ensemble-models/

Solovyev, R., Wang, W., y Gabruseva, T. (2021). Weighted boxes fusion: Ensembling boxes from different object detection models. *Image and Vision Computing, 107*, 104117. https://doi.org/10.1016/j.imavis.2021.104117

VanderPlas, J. (2022). *Python data science handbook* (2a ed.). O'Reilly Media.

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., y Plöd, M. (2023). *CRISP-ML(Q). The ML lifecycle process*. MLOps. INNOQ. https://ml-ops.org/content/crisp-ml

Wang, X., Han, X., Huang, W., Dong, D., y Scott, M. R. (2019). Multi-similarity loss with general pair weighting for deep metric learning. En *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition* (pp. 5022–5030). IEEE.

Wolpert, D. H. (1992). Stacked generalization. *Neural Networks, 5*(2), 241–259. https://doi.org/10.1016/S0893-6080(05)80023-1